Início

1 Nosso robô

- **Nome:** Kairós
- **Explicação:** Escolhemos Kairós por ser a personificação do momento oportuno, do tempo qualitativo que representa o instante certo para agir e aproveitar as oportunidades. Diferente de Chronos, que simboliza o tempo linear e quantitativo, Kairós está ligado ao tempo estratégico, aquele em que as condições se alinham e a decisão correta gera impacto. Essa dualidade conecta diretamente ao nosso propósito: enquanto o tempo cronológico fornece a base quantitativa dos modelos (CAPM e Fama-French), é o Kairós que nos lembra da importância de identificar o instante adequado para aplicar a estratégia.

2 Estratégia

- **Explicação:** Nosso robô combina a análise quantitativa de fatores de risco e alfa setorial com a observação atenta dos ciclos de mercado. Para identificar esses alfas, utilizamos o modelo CAPM aplicado em diferentes janelas de tempo, acompanhando a evolução e a robustez dos resultados. A partir desse estudo, definimos a estratégia a ser adotada. Quando o alfa setorial se mostra persistentemente diferente de zero, entendemos que há um padrão de continuidade, o que justifica a inclusão de mais fatores para explicar o retorno desses setores e aproveitar a tendência observada. Por outro lado, quando o alfa é volátil e apresenta mudanças de comportamento associadas a choques externos, sem sinal de persistência, consideramos que esses setores são altamente sensíveis a eventos imprevisíveis, difíceis de incorporar em modelos de previsão. Dessa forma, avaliamos quais setores são mais adequados para a aplicação de modelos de fatores e quais modelos são ideais para cada um, construindo ao final uma carteira com pesos alocados segundo o modelo de Markowitz.

- **Classe de Ativos:** Ações
- **Universo Investimento:** S&P 500
- **Frequência da Estratégia:** Anual
- **Benchmark:** S&P 500

Kairós

Factsheet

Robô

- Kairós é nome do nosso robô.

O tempo oporturno de agir.

Tese de Investimento

- A estratégia explora ineficiências temporárias de mercado resultantes de vieses comportamentais dos investidores, identificando ativos cujo preço não reflete plenamente o seu valor fundamental.

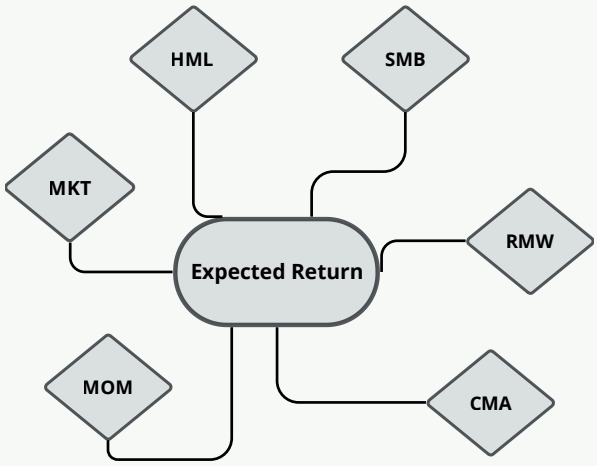

Universo de Ativos

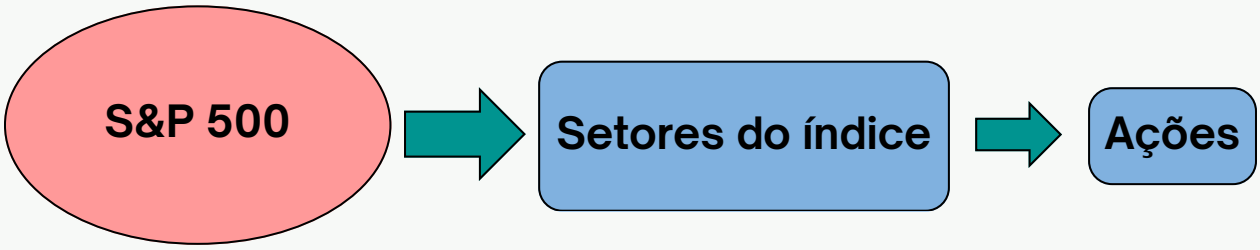

Lógica

- O processo se inicia com a captação de dados ("Puxa SPDR ETFs") para a "Análise dos Alfas" e seleção de setores. A otimização cíclica da carteira é guiada pelo "Retorno estimado para 1 ano", sendo a condição de venda acionada após 12 meses, conforme detalhado no diagrama ao lado.

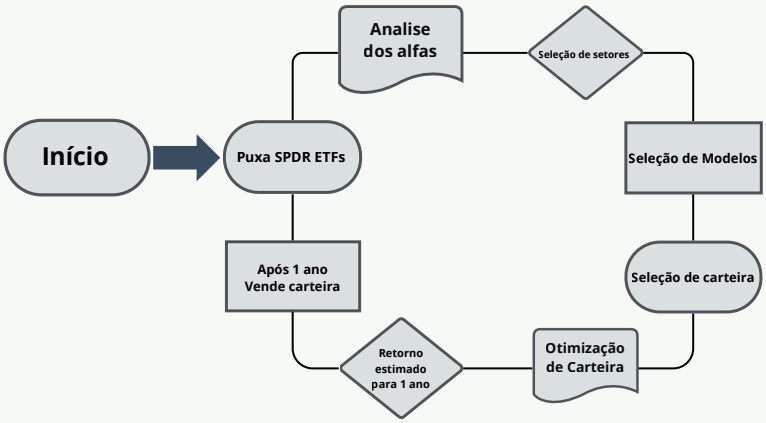

Desenvolvimento

Ideia de Investimento

A estratégia busca transformar sinais quantitativos em decisões simples de seleção e alocação setorial no S&P 500. Esse universo foi escolhido pela disponibilidade de dados padronizados dos fatores de risco e pela ausência das distorções causadas pelos juros elevados e voláteis do Brasil, permitindo distinguir melhor o que é fator, ruído ou verdadeiro alfa.

O primeiro passo consiste em analisar o comportamento do alfa ao longo do tempo. Alfas persistentes e diferentes de zero podem indicar lentidão na precificação ou ausência de fatores no modelo, enquanto alfas erráticos sugerem setores dominados por choques imprevisíveis e, portanto, menos adequados à modelagem fatorial. Essa análise é feita comparando janelas móveis e expansivas, com passos mensais e anuais, avaliando a consistência e o padrão dos sinais observados.

Após o filtro setorial, estimam-se os betas e os retornos esperados por meio dos modelos de Fama-French e Carhart. Esses retornos alimentam a otimização de Markowitz, sob restrições realistas de pesos e diversificação. O objetivo é construir uma carteira enxuta e baseada em evidências, com horizonte de um ano, que maximize o equilíbrio entre retorno esperado e risco.

Origem da Ideia

Ao longo das aulas de Finanças II, estudamos diversos modelos de fatores usados na precificação de ativos e na formação de carteiras eficientes. Esses modelos, amplamente reconhecidos no meio acadêmico, fornecem uma base teórica sólida para entender a relação entre risco e retorno.

Contudo, observamos que, apesar de sua popularidade na teoria, muitos deles têm aplicação limitada no mercado real. Essa diferença entre teoria e prática motivou-nos a desenvolver um projeto voltado a testar a eficácia desses modelos em condições reais, verificando em quais contextos eles produzem resultados consistentes.

Nosso objetivo é aproximar o rigor acadêmico da realidade operacional dos investimentos, transformando modelos teóricos em estratégias quantitativas testáveis. Assim, buscamos avaliar até que ponto os modelos de fatores podem gerar valor concreto quando aplicados de forma sistemática, levando em conta as restrições, custos e dinâmicas do mercado financeiro.

Estratégia de Investimento

α Alfa

A estratégia foi desenvolvida a partir da análise do comportamento histórico dos alfas setoriais, considerando diferentes horizontes e métodos de estimação. Os alfas foram calculados com base no modelo CAPM, escolhido por sua simplicidade e pela possibilidade de observar diretamente a sensibilidade de cada setor ao mercado, medida pelo coeficiente beta. Alfas persistentemente diferentes de zero podem indicar lentidão na precificação ou ausência de fatores relevantes no modelo, enquanto alfas voláteis tendem a refletir choques externos e imprevisíveis.

Para avaliar essa diferença, os alfas foram estimados por duas abordagens. A primeira, tradicional, obtém o alfa como intercepto da regressão entre o retorno excedente do setor e o do mercado, fornecendo uma visão ex-post do desempenho não explicado pelos fatores. A segunda, mais preditiva, calcula o alfa out-of-sample: o beta é estimado até certo ponto no tempo, e o alfa é avaliado no período seguinte, simulando uma situação real de decisão com informações apenas passadas.

Também se analisou o efeito da janela de estimação sobre a estabilidade dos resultados, testando janelas móveis e expansivas, com passos mensais e anuais. A janela móvel destaca mudanças recentes, mas gera maior volatilidade; a expansiva suaviza oscilações, evidenciando tendências de longo prazo. Durante crises como 2008 e 2020, os alfas móveis variaram intensamente, enquanto os expansivos mantiveram comportamento mais estável.

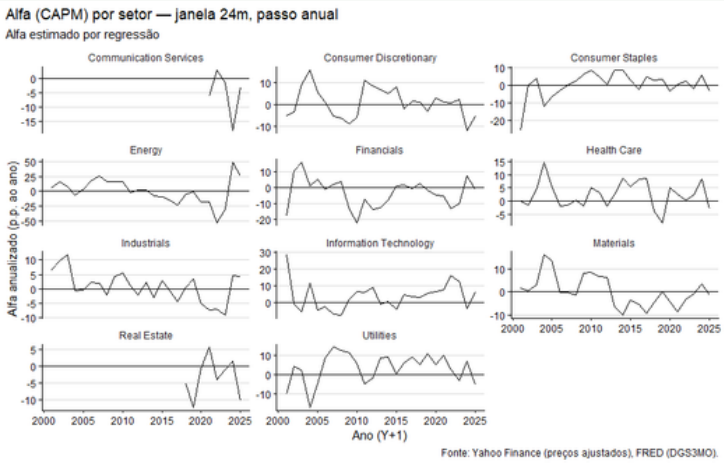

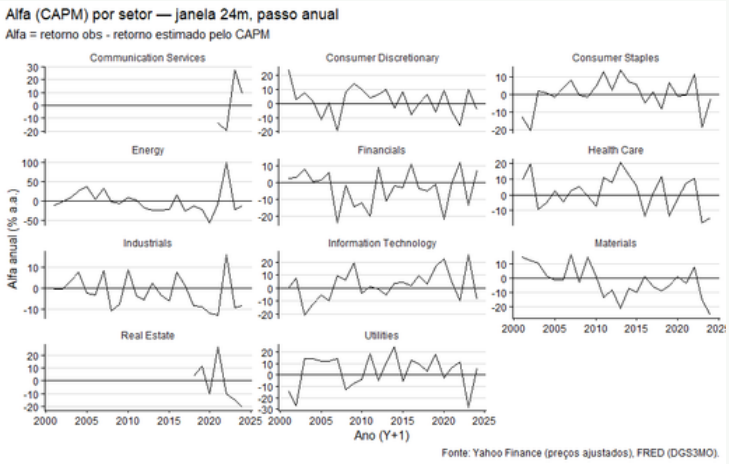

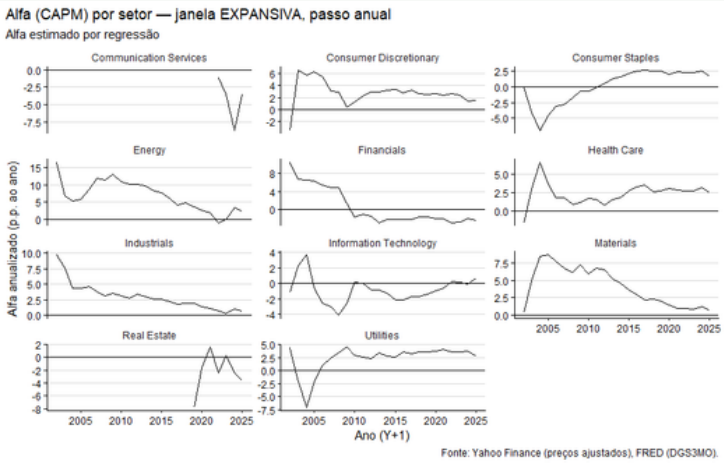

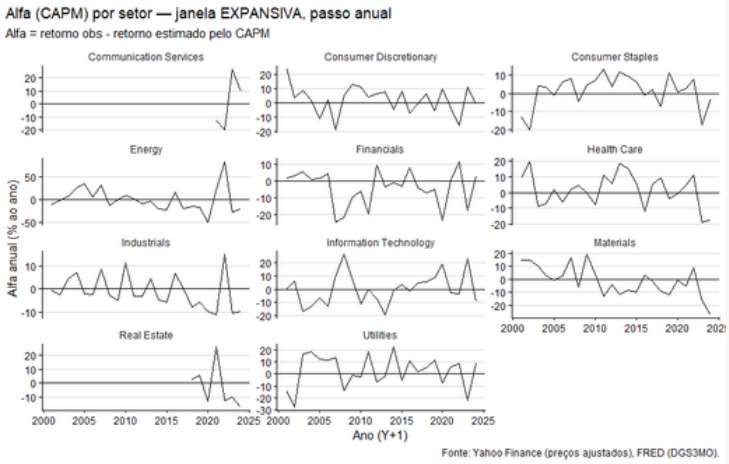

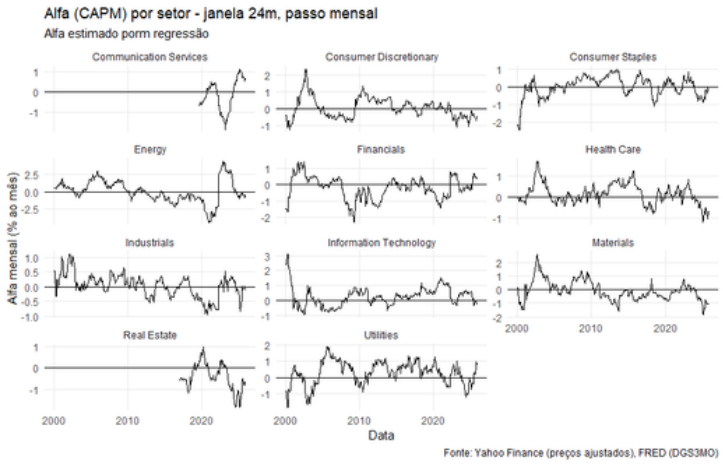

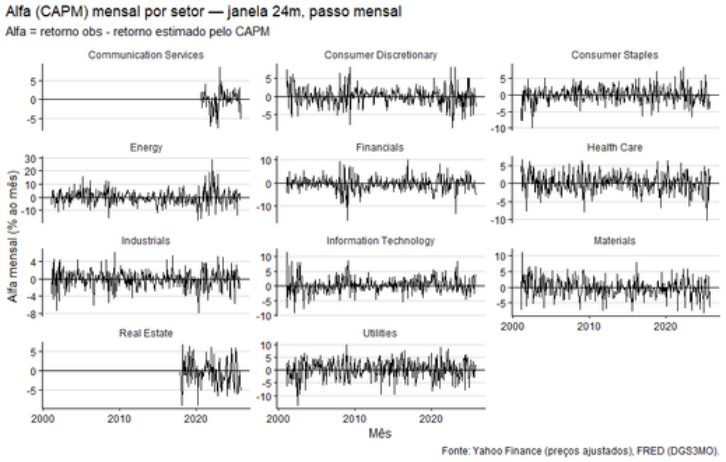

Essas análises mostraram que a persistência do alfa é um bom indicador de previsibilidade setorial. Setores com alfas consistentes respondem de forma mais estável aos fatores de risco e são mais adequados à modelagem fatorial, enquanto setores com alfas voláteis indicam maior influência de choques externos e menor potencial de previsibilidade. Essa conclusão orientou a etapa seguinte: selecionar os setores mais apropriados para o uso de modelos de fatores.

Seleção dos Setores

A seleção dos setores foi realizada com base no Índice de Persistência e Estabilidade dos Alfas (IPA), construído a partir de três dimensões: significância estatística, persistência temporal e estabilidade. Cada dimensão foi padronizada entre zero e um e ponderada segundo sua relevância 50%, 30% e 20%, respectivamente. A significância avalia se o alfa médio difere estatisticamente de zero; a persistência mede a autocorrelação temporal do sinal; e a estabilidade considera a volatilidade e as quebras estruturais. O resultado é um ranking que sintetiza a consistência dos alfas em um único indicador.

Os rankings obtidos pelos diferentes métodos foram comparados por meio da correlação de Spearman, permitindo avaliar a coerência das classificações e identificar setores robustos, independentemente da metodologia. Os resultados estão apresentados na tabela e no gráfico a seguir, que mostram a posição relativa dos setores em termos de robustez do alfa. Setores com alta persistência e baixa volatilidade foram considerados adequados para modelagem fatorial, enquanto aqueles com instabilidade ou alfa estatisticamente nulo foram excluídos. Em especial,

os setores de Comunicação (XLC) e Imobiliário (XLRE) foram removidos por apresentarem comportamento errático e choques específicos, como a reprecificação de empresas de streaming, que inviabilizam previsões sistemáticas.

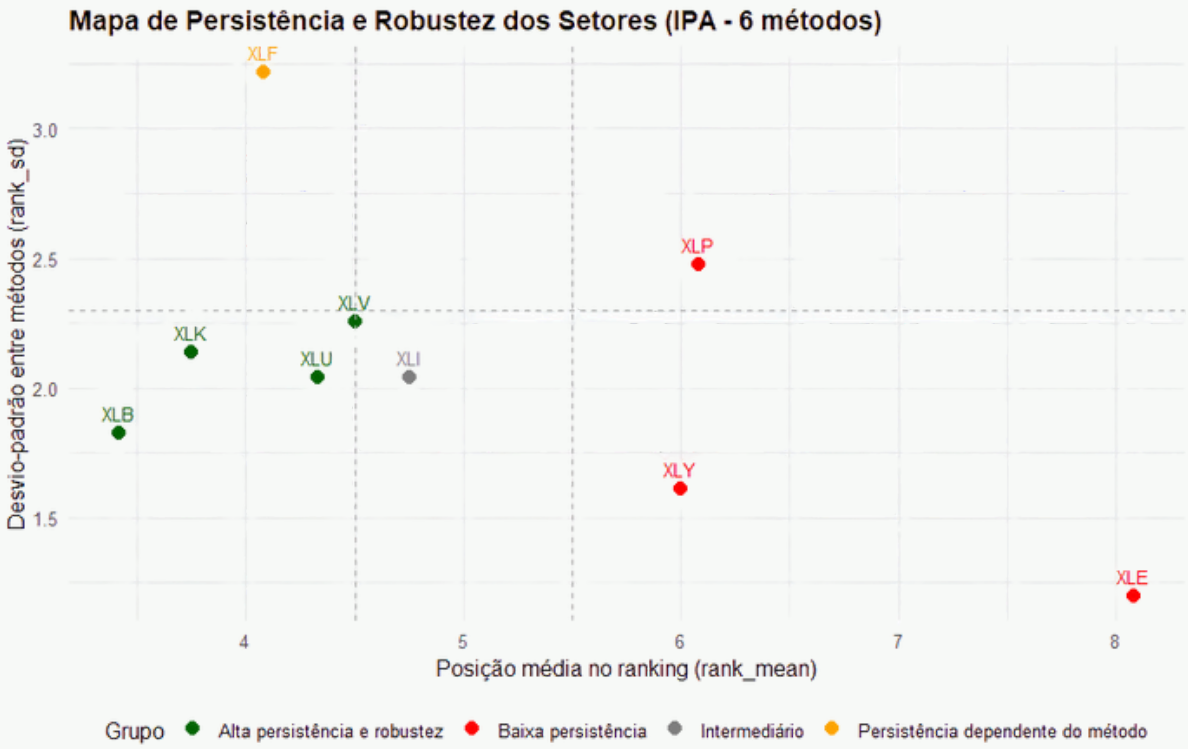

sector	exp_in	mov_anual	mov_mensal	exp_oos	mov_oos_ano	mov_oos_mes	rank_mean	rank_sd	grupo
XLB	2.5	4.5	5.0	2.0	1.0	5.5	3.417	1.828	Alta persistência e robustez
XLK	2.5	2.5	2.5	6.5	6.5	2.0	3.750	2.139	Alta persistência e robustez
XLF	9.0	4.5	2.5	1.0	6.5	1.0	4.083	3.216	Persistência dependente do método
XLU	2.5	2.5	2.5	6.5	6.5	5.5	4.333	2.041	Alta persistência e robustez
XLV	5.0	1.0	2.5	6.5	6.5	5.5	4.500	2.258	Alta persistência e robustez
XLI	2.5	6.5	7.5	3.5	3.0	5.5	4.750	2.043	Intermediário
XLY	7.0	6.5	7.5	6.5	3.0	5.5	6.000	1.612	Baixa persistência
XLP	8.0	9.0	7.5	3.5	3.0	5.5	6.083	2.478	Baixa persistência
XLE	6.0	8.0	7.5	9.0	9.0	9.0	8.083	1.201	Baixa persistência

Seleção de Modelos

Com o universo de setores definido, a etapa seguinte foi determinar o modelo mais adequado para cada um deles. Para isso, foram testados os modelos de Fama e French de três e cinco fatores, além do modelo de quatro fatores de Carhart, que adiciona o fator momentum. A escolha foi feita comparando o valor absoluto do alfa mensal e o R^2 ajustado das regressões. O modelo preferido é aquele que minimiza o valor do alfa, ou seja, explica melhor os retornos, e que apresenta o maior R^2 ajustado entre as alternativas. Essa abordagem busca um equilíbrio entre parcimônia e capacidade explicativa, evitando tanto a inclusão desnecessária de fatores quanto o risco de omitir fontes relevantes de risco.

Os resultados dessa comparação estão apresentados na tabela a seguir, onde se observa que os modelos ideais variam entre os setores, reforçando que a estrutura de risco não é homogênea no mercado. Para o setor de Materiais (XLB), o modelo de Carhart apresentou o melhor desempenho, sugerindo que o fator momentum é importante para capturar a dinâmica das commodities e dos ciclos industriais. Já os setores Financeiro (XLF) e de Saúde (XLV) foram melhor explicados pelo modelo de cinco fatores, o que indica sensibilidade aos fatores de rentabilidade e investimento, além dos tradicionais tamanho e valor. Por outro lado, os setores Industrial (XLI) e de Tecnologia (XLK) foram bem representados pelo modelo de três fatores, mostrando que a estrutura clássica de Fama e French ainda é

suficiente nesses casos. Essa diferenciação mostra que a diversificação entre setores não deve se limitar aos ativos, mas também se estende à forma de modelar o risco e o retorno esperado.

Resultados dos Modelos Fatoriais por Setor

Setor	Modelo	n	Alfa mensal	R^2 ajustado
XLB	Carhart 4	320	−0,00053	0,699
XLF	FF5	320	−0,00088	0,863
XLI	FF3	320	−0,00017	0,832
XLK	FF3	320	0,00079	0,841
XLU	FF5	320	0,00039	0,299
XLV	FF5	320	0,00065	0,593

Carteira eficiente

Com os modelos setoriais definidos, iniciou-se a estimação dos retornos esperados com dados mensais de 2015 a 2025 e janela mínima de 60 meses. As expectativas dos fatores foram calculadas como a média dos últimos 36 meses até agosto de 2025, refletindo o comportamento recente do mercado. A partir dos betas de cada ação e dos valores médios esperados dos fatores, obtiveram-se os retornos esperados, posteriormente anualizados. Apenas ações com R^2 acima de 0,5 foram mantidas, assegurando relações estatisticamente significativas.

Com a base consolidada, aplicou-se a otimização de Markowitz para determinar os pesos da carteira, sob restrições realistas: ausência de posições vendidas, limite de 5% por ativo e soma dos pesos igual a 100%. A matriz de covariância foi anualizada e o modelo buscou a carteira tangente, que maximiza o índice de Sharpe considerando um prêmio de risco de 4% ao ano. Essa abordagem equilibra retorno e risco com base em relações empíricas robustas.

Os resultados estão apresentados na tabela e no gráfico seguintes, que mostram a fronteira eficiente, a carteira tangente e os pesos finais. O setor de Utilities (XLU) foi excluído devido ao R^2 consistentemente baixo, indicando retornos dominados por choques idiossincráticos, o que comprometeria a previsibilidade e a estabilidade da carteira.

```
--- Carteira Tangente (Máx. Sharpe) ---
> cat("Retorno esperado (anual):", round(retorno_max_sharpe * 100, 2), "%\n")
Retorno esperado (anual): 25.44 %
> cat("Volatilidade anual:",      round(risco_max_sharpe   * 100, 2), "%\n")
Volatilidade anual: 18.32 %
> cat("Sharpe anual:",            round(sharpe_max, 3), "\n")
Sharpe anual: 1.17
```

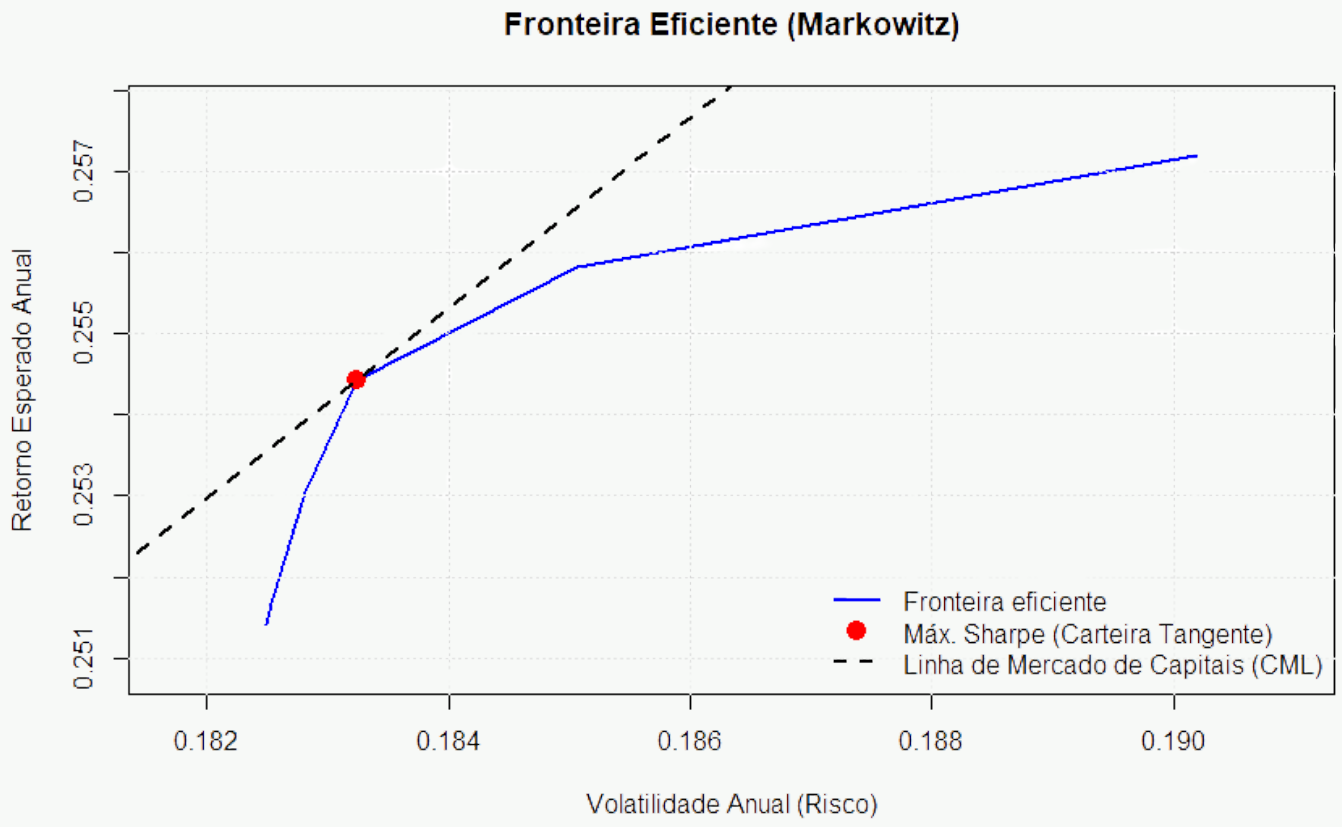

Backtest

Por fim, a estratégia foi submetida a uma série de backtests para avaliar sua consistência em diferentes contextos de mercado e verificar se os resultados obtidos poderiam ser reproduzidos fora da amostra de calibração. O procedimento repetiu exatamente o mesmo código e parâmetros da etapa principal, alterando apenas o período de análise. Em cada iteração, as regressões fatoriais, as médias dos fatores, os filtros de R^2 e a otimização de Markowitz foram recalculados com base nas informações disponíveis até o final de cada janela, simulando a perspectiva de um investidor naquele momento.

Os backtests foram aplicados em seis períodos de referência dezembro de 2010, 2012, 2014, 2016, 2018 e 2023, estimando o retorno esperado para o ano seguinte em cada caso. Essa abordagem escalonada permitiu observar a estabilidade da seleção de setores, a variação na escolha dos modelos fatoriais e a sensibilidade da carteira às condições econômicas de cada época. Em todas as simulações, os parâmetros e restrições foram mantidos constantes, garantindo comparabilidade direta entre os períodos.

Diversas medidas foram adotadas para evitar vieses comuns em modelos preditivos. O look-ahead bias foi eliminado ao restringir as informações de estimação a dados anteriores à data de referência. As médias dos fatores foram calculadas apenas até o mês imediatamente anterior, e os betas, obtidos em janelas históricas limitadas. As taxas livres de risco refletiram as condições econômicas vigentes, baseadas nos títulos do Tesouro norte-americano de curto prazo, assegurando coerência entre o ambiente de mercado e o cálculo do prêmio de risco. A prova dessa coerência é observada na mudança dos setores selecionados em cada época, ilustrada nos gráficos abaixo.

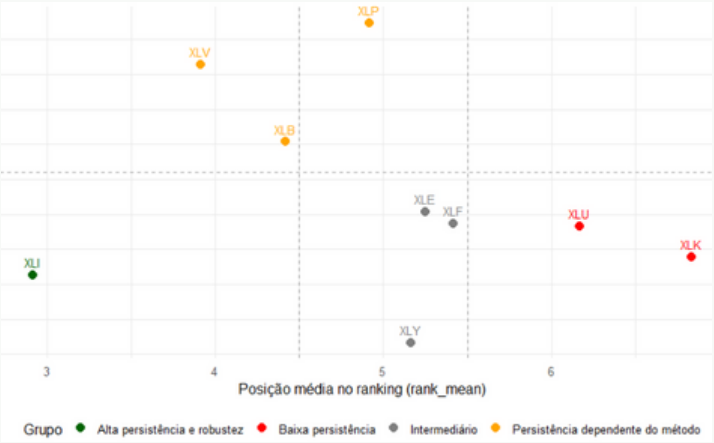

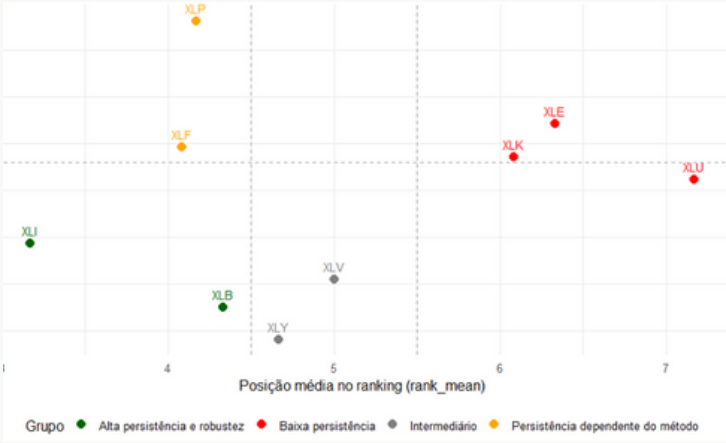

Para evitar overfitting, o tamanho das janelas, os limiares de R^2 e as restrições de pesos foram mantidos fixos, e os modelos fatoriais limitaram-se às formulações clássicas. Nas tabelas seguintes, são comparados os retornos estimados e os retornos efetivos observados em cada período de backtest.

2011			
Retorno Esperado	Retorno Realizado	Erro de previsão	Retorno de mercado
15,8%	2,5%	-13,3%	2,11%

2013			
Retorno Esperado	Retorno Realizado	Erro de previsão	Retorno de mercado
21,7%	44,9%	23,2%	32,39%

2015			
Retorno Esperado	Retorno Realizado	Erro de previsão	Retorno de mercado
44,7%	-1,7%	-45%	1,38%

2017			
Retorno Esperado	Retorno Realizado	Erro de previsão	Retorno de mercado
21%	21%	0	21,83%

2019			
Retorno Esperado	Retorno Realizado	Erro de previsão	Retorno de mercado
15,4%	31,2%	15,8%	31,49%

2024			
Retorno Esperado	Retorno Realizado	Erro de previsão	Retorno de mercado
23%	4,8%	-18,2%	25,02%

Conclusão

A estratégia mostrou resultados promissores e potencial de aplicação, mas ainda requer aprimoramentos antes de uso real. Os testes indicaram consistência estatística e boa estrutura de estimação, embora o desempenho varie conforme o período com forte aderência em anos como 2013 e 2017 e resultados mais modestos em outros, refletindo as mudanças de mercado.

Um ponto crítico é a correlação entre ações de um mesmo setor, que reduz a diversificação e limita a eficiência da carteira. Futuras versões devem incorporar ativos de diferentes naturezas ou métodos que controlem a correlação na alocação.

Os alfas persistentes, antes interpretados como falhas de modelagem de fatores, podem também indicar lentidão na precificação setorial. Essa hipótese sugere integrar sinais de momentum, combinando fundamentos fatoriais e dinâmicas de tendência.

Assim, embora ainda não pronta para implementação prática, a estratégia estabelece uma base sólida para evolução, com próximos passos voltados à diversificação e à incorporação de momentum nos setores com precificação mais lenta.

IA Generativa

Experiências com a IA

Neste projeto, a IA generativa (ChatGPT, Gemini e NotebookLM) funcionou como suporte principal para integrar nosso conhecimento em finanças e estatística à programação quantitativa. O objetivo central era acelerar o desenvolvimento de um robô de investimento. A aplicação da IA foi ampla, abrangendo desde a criação da identidade (nome e logo) até tarefas complexas, como a programação dos códigos em R, a discussão da teoria financeira da estratégia e a montagem do backtest.

Primeiro output

Último output

A decisão de usar a IA baseou-se no alto ganho de produtividade. O impacto mais significativo foi na programação. Em vez de escrever o código em R do zero, passávamos a ideia lógica para a IA, otimizando o desenvolvimento. Além de gerar código, a IA foi vital para a correção de bugs e identificação rápida de erros na nossa lógica e nas bibliotecas do R.

Apesar dos benefícios, surgiram limitações relacionadas à necessidade de "treinamento" da ferramenta. Inicialmente, a IA não entendia nossa necessidade, como visto nas primeiras tentativas para a logo e nos prompts de código. Um desafio constante era a falta de memória da IA: de um dia para o outro, ela esquecia a lógica sofisticada estabelecida na sessão anterior, exigindo que o prompt fosse treinado novamente para restaurar a espiral de acerto. Além disso, a IA frequentemente adicionava informações extras e blocos de código não solicitados, o que gerava retrabalho na depuração e atrasava o andamento. Com a insistência nos prompts, no entanto, a qualidade do código gerado melhorou drasticamente.

Em reflexão final, o projeto demonstrou que a IA é uma ferramenta de suporte essencial, capaz de turbinar a produtividade. Em finanças quantitativas, o potencial é imenso. A IA não só agilizou o desenvolvimento e o backtest, mas também serviu como "parceira de discussão", oferecendo insights estratégicos, como sugestões nos critérios de avaliação e composição da carteira de ativos. Apesar disso, ainda vemos que a IA comete erros em assuntos técnicos e específicos, principalmente de finanças estatística. Entretanto, tem um futuro muito próspero.

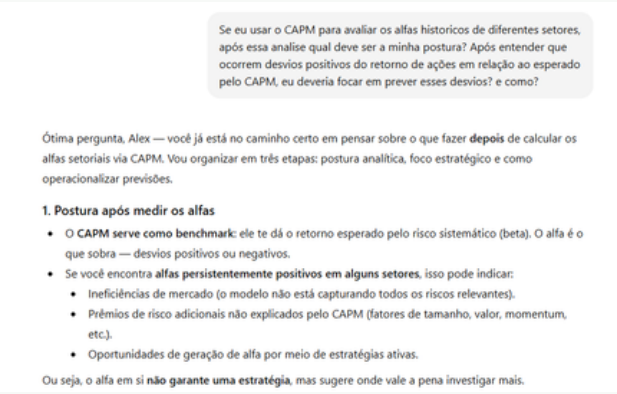

Se eu usar o CAPM para avaliar os alfas historicos de diferentes setores, após essa analise qual deve ser a minha postura? Após entender que ocorrem desvios positivos do retorno de ações em relação ao esperado pelo CAPM, eu deveria focar em prever esses desvios? e como?

Ótima pergunta, Alex — você já está no caminho certo em pensar sobre o que fazer **depois** de calcular os alfas setoriais via CAPM. Vou organizar em três etapas: postura analítica, foco estratégico e como operacionalizar previsões.

1. Postura após medir os alfas

- O **CAPM serve como benchmark**: ele te dá o retorno esperado pelo risco sistemático (beta). O alfa é o que sobra — desvios positivos ou negativos.
- Se você encontra **alfas persistentemente positivos em alguns setores**, isso pode indicar:
  - Ineficiências de mercado (o modelo não está capturando todos os riscos relevantes).
  - Prêmios de risco adicionais não explicados pelo CAPM (fatores de tamanho, valor, momentum, etc.).
  - Oportunidades de geração de alfa por meio de estratégias ativas.

Ou seja, o alfa em si **não garante uma estratégia**, mas sugere onde vale a pena investigar mais.

À direita, temos um exemplo de prompt inicial utilizado para o desenvolvimento de código. Esse primeiro resultado raramente funcionava integralmente, mas servia como uma base sólida para ajustarmos erros e refinarmos nossas ideias.

À esquerda, temos um exemplo de apoio da IA no desenvolvimento de ideias, principalmente quando enfrentávamos bloqueios criativos

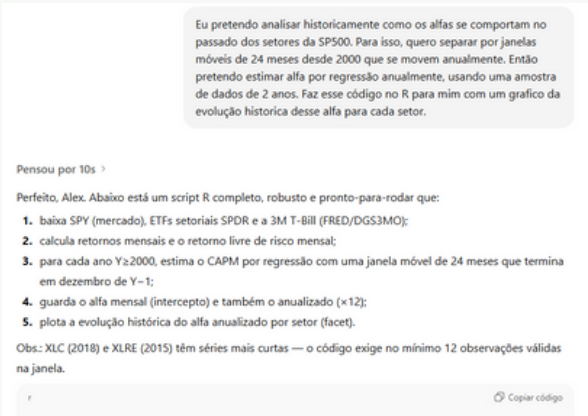

Eu pretendo analisar historicamente como os alfas se comportam no passado dos setores da SP500. Para isso, quero separar por janelas móveis de 24 meses desde 2000 que se movem anualmente. Então pretendo estimar alfa por regressão anualmente, usando uma amostra de dados de 2 anos. Faz esse código no R para mim com um grafico da evolução historica desse alfa para cada setor.

Pensou por 10s

Perfeito, Alex. Abaixo está um script R completo, robusto e pronto-para-rodar que:

1. baixa SPY (mercado), ETFs setoriais SPDR e a 3M T-Bill (FRED/DGS3MO);
2. calcula retornos mensais e o retorno livre de risco mensal;
3. para cada ano Y≥2000, estima o CAPM por regressão com uma janela móvel de 24 meses que termina em dezembro de Y−1;
4. guarda o alfa mensal (intercepto) e também o anualizado (×12);
5. plota a evolução histórica do alfa anualizado por setor (facet).

Obs.: XLC (2018) e XLRE (2015) têm séries mais curtas — o código exige no mínimo 12 observações válidas na janela.

Copiar código

Bibliografia

Referências

Os dados utilizados na construção e validação da estratégia foram obtidos a partir de fontes públicas e amplamente reconhecidas no meio acadêmico e financeiro. Os fatores de risco dos modelos CAPM, Fama-French e Carhart foram extraídos da base Fama-French Data Library, mantida pela Dartmouth College, que fornece séries históricas mensais dos principais fatores de mercado, tamanho, valor, lucratividade, investimento e momentum. As informações sobre os ETFs setoriais utilizadas na segmentação da análise foram obtidas diretamente do site oficial Sector SPDRs (https://www.sectorspdrs.com/allsectors), que disponibiliza as composições atualizadas e os históricos de holdings de cada fundo. Já os preços ajustados das ações e dos índices de mercado foram extraídos do Yahoo Finance, por meio da biblioteca quantmod em R, garantindo consistência e atualização das cotações empregadas.

Como fundamentação teórica e suporte conceitual para a implementação e interpretação da estratégia, foram utilizados os seguintes livros clássicos de finanças: Finanças Empresariais: Essencial de Jonathan Berk e Peter DeMarzo (Editora Bookman, 2009), Mercados Financeiros e Estratégias Corporativas de Mark Grinblatt e Sheridan Titman (Bookman Editora, 2ª edição), e Investimentos de Zvi Bodie, Alex Kane e Alan Marcus (10ª edição, McGraw-Hill/Irwin). Essas referências forneceram a base conceitual necessária para a aplicação prática dos modelos de precificação de ativos, avaliação de risco e otimização de portfólios utilizados ao longo do projeto.